

# Modelação e Previsão de Consumo mensal de Eletricidade em Portugal (Gwh)

André Catarino | 56788

Diana Salvador | 56370

Diogo Valente | 56662

Inês Caseiro | 48764

Sara Lopes | 52000

Yiqing Zhu | 52219

Lisbon School of Economics and Management - ISEG

**Resumo:** O presente trabalho analisa e modela a série sazonal do consumo mensal de eletricidade em Portugal. Realiza-se uma análise dos dados, com o objetivo de encontrar o melhor modelo entre os possíveis selecionados. Na identificação dos mesmos foram aplicados métodos de Alisamento Exponencial e modelos SARIMA. O modelo em destaque, entre os 5 modelos selecionados, é o modelo SARIMA (1,1,1) (0,1,1)<sub>12</sub>. Os resultados da previsão para o futuro são os expectáveis.

**Palavras-Chave:** Consumo de Eletricidade, Alisamento Exponencial, SARIMA, Erros de Previsão, Previsão.

## 1. Introdução

O presente trabalho pretende modelar o comportamento do consumo mensal de eletricidade em Portugal, com o objetivo de obter uma previsão para a futura evolução do consumo, num horizonte temporal de 12 meses. Numa primeira abordagem, observaram-se e analisaram-se os dados desta série. Com os conhecimentos adquiridos na Unidade Curricular de Métodos de Previsão, decompôs-se a série em vários fatores, e com as características identificadas na série, foram aplicados modelos de Alisamento Exponencial e modelos SARIMA, de forma a entender qual o melhor entre estes. Por fim, foi realizada a previsão para o futuro, utilizando o modelo selecionado.

### 1.1. Definição do problema

O tema da série selecionada para este trabalho tem como intuito entender o comportamento e evolução do consumo de eletricidade em Portugal. O estudo da evolução deste consumo torna-se pertinente devido ao panorama atual que é consequência de fatores como a alteração do nível de preços, o avanço tecnológico, a sensibilização ambiental e, mais recentemente, a pandemia.

### 1.2. Recolha e descrição dos dados




Figura 1- Consumo mensal de Eletricidade em Portugal (GWh). Fonte: REN




Figura 2- Consumo mensal de Eletricidade em Portugal (Gwh)




Figura 3- Consumo Mensal de Eletricidade em Portugal (Gwh)

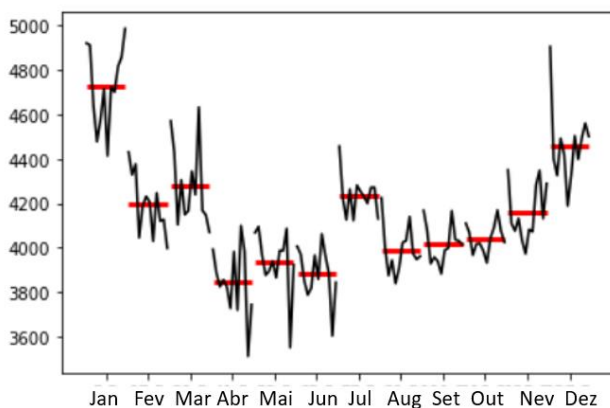


Figura 4- Gráfico de subséries sazonais




Figura 5- Heatmap

A figura 1 contém a série representativa do consumo mensal de eletricidade em Portugal, em GWh, entre janeiro de 2010 e dezembro de 2021. Pela observação da figura 1 é perceptível a existência de sazonalidade com picos em janeiro e julho, fenómeno comprovável através da figura 2. A amplitude da sazonalidade parece aumentar desde 2013 até 2021. O pico máximo da série é atingido em janeiro de 2021 (4985 GWh), e o mínimo em abril de 2020 (3512 GWh), sendo justificado pelo 1º confinamento que começou em março de 2020 e originou o encerramento de muitas empresas e fábricas em Portugal (figura 3). Pela análise do gráfico na figura 4, que representa a média do agregado do consumo mensal e destaca os padrões sazonais, pode concluir-se que os meses com um consumo mais elevado são janeiro, dezembro, março e julho, e os meses com menor consumo são abril, maio e junho, informação também visível na figura 5.

Os dados utilizados neste trabalho foram extraídos do site da REN (Redes Energéticas Nacionais).

### 1.3. Revisão da literatura empírica

A eletricidade que é consumida em Portugal é ainda em grande parte produzida no exterior, no entanto a dependência energética é cada vez menor. Por exemplo, em 2009 Portugal apresentava uma dependência energética de 81,2%, e em 2019 esse valor situou-se nos 74,2%. Um dos principais objetivos da política energética nacional é reduzir essa dependência para 65% até 2030.

Por outro lado, as energias renováveis têm um peso cada vez maior em Portugal. Em 2019, estas representaram 30,6% do consumo final de energia, e em 2021, 31%. Para 2030 o país tem como meta os 47% (Direção-Geral de Energia e Geologia, 2021).

É de salientar que o setor dos transportes, à semelhança dos últimos anos, continua a ser o principal consumidor de energia, representando, em 2019, 36,1% do consumo total de energia final.

Por fim, é de realçar que o consumo de eletricidade em 2020 foi o menor registado nos últimos 15 anos, atingindo o valor de 48 800 GWh, menos 3,1% face ao ano anterior, dados fornecidos pela REN. Este facto é explicado pela pandemia que se iniciou em Portugal neste mesmo ano (Lusa, 2021).

## 2. Decomposição das forças componentes




Figura 6- Decomposição da série através do Modelo Multiplicativo

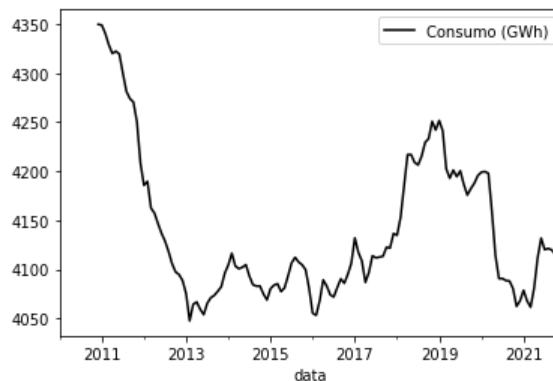


Figura 7- Representação da tendência-cíclica da série

Para escolher qual o modelo de decomposição a utilizar, de entre os estudados, foram aplicados ambos os modelos (Modelo Aditivo e Modelo Multiplicativo). Tendo em conta que a série residual possuía estrutura no Modelo Aditivo, optou-se pela aplicação do Modelo Multiplicativo ( $Y_t = TC_t \times S_t \times E_t$ ), mesmo não sendo clara a existência de interdependência entre tendência e sazonalidade.

Os resultados da decomposição desta série estão evidenciados na figura 6. Relativamente à tendência, que é representada na figura 7, é notável algumas alterações ao longo do tempo. De 2010 a 2013 é visível uma tendência decrescente acentuada, possivelmente relacionada com a crise financeira. A partir desta data, a tendência é geralmente crescente até 2019. De 2019 a 2021 é maioritariamente decrescente, provavelmente devido ao início do confinamento.

## 3. Métodos de Alisamento Exponencial

### 3.1. Revisão de literatura

Segundo Makridakis, Wheelwright, & Hyndman (1998), Winters, em 1960, estendeu o método de Holt, de forma a permitir prever séries temporais com sazonalidade. Este método recorre a três parâmetros de alisamento,  $0 < \alpha < 1$ ,  $0 < \beta < 1$  e  $0 < \gamma < 1$ .

#### Alisamento Exponencial de Holt-Winters Aditivo:

Este método de previsão aplica-se caso a amplitude da componente sazonal não aumente com a tendência, ou seja, caso haja independência entre elas.

Equação de previsão a k períodos:

$$\hat{Y}_{t+k} = a_t + kb_t + S_{t+k-s}, \text{ com:}$$

$$a_t = \alpha(Y_t - S_{t-s}) + (1 - \alpha)(a_{t-1} + b_{t-1}) \text{ (nível)}$$

$$b_t = \beta(a_t - a_{t-1}) + (1 - \beta)b_{t-1} \text{ (declive)}$$

$$S_t = \gamma(Y_t - a_t) + (1 - \gamma)S_{t-s} \text{ (fator sazonal, com } s \text{ o número de períodos do ciclo sazonal)}$$

### Alisamento Exponencial de Holt-Winters Multiplicativo:

Este método de previsão aplica-se caso a amplitude da componente sazonal aumente com a tendência, ou seja, caso haja interdependência entre elas.

Equação de previsão a  $k$  períodos:

$$\hat{Y}_{t+k} = (a_t + kb_t)S_{t+k-s}, \text{ com:}$$

$$a_t = \alpha(Y_t/S_{t-s}) + (1 - \alpha)(a_{t-1} + b_{t-1}) \text{ (nível)}$$

$$b_t = \beta(a_t - a_{t-1}) + (1 - \beta)b_{t-1} \text{ (declive)}$$

$$S_t = \gamma\left(\frac{Y_t}{a_t}\right) + (1 - \gamma)S_{t-s} \text{ (fator sazonal, com } s \text{ o número de períodos do ciclo sazonal)}$$

### Outros Métodos:

Além destes métodos, existem outros que resultam da combinação entre os tipos de sazonalidade (aditiva e multiplicativa) e os tipos de tendência (aditiva, multiplicativa, linear, amortecida aditiva, amortecida multiplicativa e exponencial), que podem fornecer melhores resultados (Hyndman & Athanasopoulos, 2014).

### 3.2. Identificação do método de Alisamento Exponencial

A série temporal sazonal escolhida consiste num conjunto de dados mensais, de janeiro de 2010 a dezembro de 2021, sobre o consumo, em GWh, de eletricidade em Portugal. Existem 144 observações, sendo que as 115 primeiras constituem a amostra de treino e as 29 últimas a amostra de teste.

Aplicou-se o método de Alisamento Exponencial de Holt-Winters Multiplicativo, e o método de Alisamento Exponencial com Tendência Aditiva Amortecida e Sazonalidade Multiplicativa.

No *software Python*, obteve-se o gráfico que compara os dados da amostra de teste com os dados da previsão, para cada um dos dois métodos utilizados.




Figura 8- Método de Alisamento Exponencial de Holt-Winters Multiplicativo




Figura 9- Método de Alisamento Exponencial com Tendência Aditiva Amortecida e Sazonalidade Multiplicativa

Através da observação gráfica, conclui-se que o melhor método a utilizar é o Alisamento Exponencial com Tendência Aditiva Amortecida e Sazonalidade Multiplicativa.

## 4. Modelos SARMA e SARIMA

### 4.1. Revisão de literatura

Aos modelos ARMA, além das componentes autorregressivas (AR) e médias móveis (MA), pode ser implementada a componente sazonal, originando os modelos SARMA (seasonal *autoregressive moving average*).

#### Modelos SARMA( $P, Q$ )<sub>S</sub>:

Os modelos SARMA podem ser processos estacionários e invertíveis mediante certas condições, são utilizados para séries temporais sazonais, e caracterizam as próprias séries.

$$Y_t = \Phi_1 Y_{t-s} + \dots + \Phi_p Y_{t-ps} + \varepsilon_t - \theta_1 \varepsilon_{t-s} - \dots - \theta_Q \varepsilon_{t-Qs}$$

Este modelo é acompanhado dos parâmetros  $\Phi_P$ , que representa o parâmetro sazonal autorregressivo de ordem P, e  $\theta_Q$ , que representa o parâmetro sazonal de médias móveis de ordem Q

Os modelos SARMA apresentam a forte limitação de poderem ser praticáveis apenas em condições de estacionariedade dos dados.

#### Modelos SARIMA(p, d, q)(P, D, Q)<sub>S</sub>:

Para que os modelos SARMA estejam aptos a dados não estacionários, deve ser adicionada ao modelo a componente integrada (I), dando assim origem aos modelos SARIMA.

$$(1 - \phi_1 L - \dots - \phi_p L^p)(1 - \Phi_1 L^s - \dots - \Phi_P L^{Ps})(1 - L)^d(1 - L^s)^D Y_t = (1 - \theta_1 L - \dots - \theta_q L^q)(1 - \Theta_1 L^s - \dots - \Theta_Q L^{Qs}) \varepsilon_t \quad (L \text{ é o operador de atraso})$$

O operador  $(1 - L)^d$  refere-se ao operador de diferenciação de ordem d,  $d \geq 1$ , e o operador  $(1 - L^s)^D$  refere-se ao operador de diferenciação sazonal de ordem D,  $D \geq 1$ .

### 4.2. Identificação dos modelos SARMA ou SARIMA

#### Correlograma:

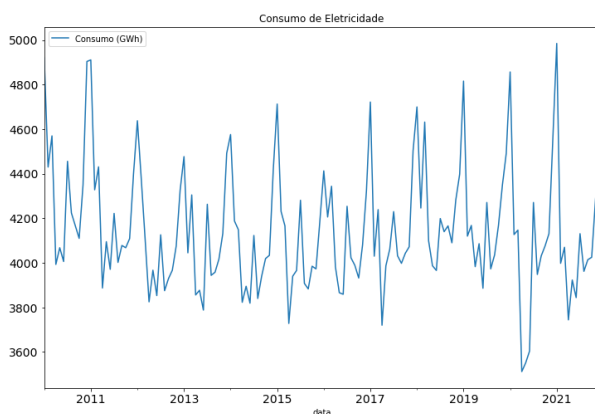


Figura 10- Representação gráfica da série




Figura 11- Correlograma da série

Recorrendo apenas à observação do seu gráfico, a estacionariedade da série temporal sazonal apresentada é inconclusiva.

Através do correlograma da mesma série, conclui-se que a FAC apresenta um decaimento sinusoidal na série e um decaimento exponencial amortecido nos múltiplos de 11. Em relação à FACP, esta apresenta uma queda mais acentuada do lag 1 para o lag 2 e do lag 12 para o lag 24. Deste modo, apenas com base nos dados originais, depreende-se que modelo mais adequado será um SARIMA (1,0,0)(1,0,0)<sub>12</sub>.

#### Resultados (Teste Dickey-Fuller Aumentado e Transformações):

Resultados do teste Dickey-Fuller:	Original	Logarítmo	1ª diferença sazonal	1ª diferença simples e sazonal
Test Statistic	-2.873792	-2.770389	-2.707494	-4.064716
p-value	0.048482	0.062630	0.072750	0.001107
#Lags Used	11	11	12	12
Nº of Obs Used	103	103	90	89
Critical Value (1%)	-3.495493	-3.495493	-3.505190	-3.506057
Critical Value (5%)	-2.890037	-2.890037	-2.894232	-2.894607
Critical Value (10%)	-2.581971	-2.581971	-2.584210	-2.584410

Tabela 1- Resultados do teste Dickey-Fuller Aumentado

#### Resultado do teste para os dados originais:

Aplicando o teste Dickey-Fuller Aumentado para testar a estacionariedade da série em causa, obteve-se um valor  $p = 0.048$ , o que leva à não rejeição da hipótese nula para um nível de significância de 1%. Desta forma, entende-se que a série original é não estacionária ao nível de significância definido.

#### Resultado do teste para os dados transformados:

Sendo uma série sazonal, em primeiro lugar, deve aplicar-se a diferenciação sazonal de modo a entender se após o processo de diferenciação, a série se torna efetivamente estacionária. Como observado na tabela, a série ainda não é estacionária. Assim, deve proceder-se a uma diferenciação simples e sazonal. Deste modo, conclui-se que o processo que apresenta um valor-p mais favorável a nível de estacionariedade e da invertibilidade das raízes é a aplicação de uma diferenciação simples e sazonal aos dados originais, ao nível de significância de 1%, tornando os dados satisfatórios para aplicar o modelo SARIMA.

#### Seleção dos modelos:

	SARIMA (1, 1, 1)(1, 1, 1) <sub>12</sub>	SARIMA (1, 1, 3)(1, 1, 1) <sub>12</sub>	SARIMA (1, 1, 1)(0, 1, 1) <sub>12</sub>
$\phi$ (valor-p)	$\hat{\phi}_1 = 0.2047$ (0.114)	$\hat{\phi}_1 = 0.9781$ (0.000)	$\hat{\phi}_1 = 0.2145$ (0.091)
$\theta$ (valor-p)	$\hat{\theta}_1 = -0.8068$ (0.000)	$\hat{\theta}_1 = -1.5624$ (0.000) $\hat{\theta}_2 = 0.3625$ (0.048) $\hat{\theta}_3 = 0.2128$ (0.022)	$\hat{\theta}_1 = -0.8179$ (0.000)
$\Phi$ (valor-p)	$\hat{\Phi}_1 = -0.3303$ (0.020)	$\hat{\Phi}_1 = -0.3202$ (0.020)	
$\Theta$ (valor-p)	$\hat{\Theta}_1 = -0.6249$ (0.000)	$\hat{\Theta}_1 = -0.6468$ (0.000)	$\hat{\Theta}_1 = -0.9796$ (0.296)
Estacionariedade	Sim	Sim	Sim
Invertibilidade	Sim	Sim	Sim
Resíduos são ruído branco?	Sim	Sim	Sim
Valor-p da estatística Q	0.97	0.94	0.99
AIC	1262.368	1264.478	1264.952
BIC	1275.493	1282.853	1275.452

Tabela 2- Características dos modelos selecionados

De acordo com a tabela acima apresentada, podem extrair-se algumas conclusões que permitem compreender quais os melhores modelos de previsão da série em estudo. Essas conclusões são recolhidas através do teste de significância individual, dos correlogramas dos resíduos de cada modelo (em anexo) onde se verifica se há indícios de estrutura da série dos resíduos, e do teste de hipóteses Ljung-Box, que permite estudar a correlação dos resíduos do modelo, sendo que o objetivo é não rejeitar a hipótese nula (os resíduos têm o comportamento de um ruído branco). Por fim, são apresentados dois critérios de seleção de modelos (AIC e BIC), e quanto menor for o seu valor melhor será o seu ajustamento do modelo aos dados.

Conclui-se que todos os parâmetros são estatisticamente não significativos a um nível de significância de 5%, excepto o AR do modelo SARIMA  $(1,1,1)(1,1,1)_{12}$  e o AR e SMA do modelo SARIMA  $(1,1,1)(0,1,1)_{12}$ . Em relação aos resíduos, de acordo com os correlogramas, estes aproximam-se de um ruído branco para qualquer modelo, o que corrobora as conclusões retiradas através do teste do Ljung-Box, pois como a estatística Q apresenta valores-p superiores a qualquer nível de confiança, procede-se à não rejeição da hipótese nula, confirmando-se assim a ausência de correlação entre os resíduos.

No *software Python*, obtiveram-se os gráficos que comparam os dados da amostra de teste com os dados da previsão, para cada um dos três métodos utilizados.




Figura 12- Método SARIMA  $(1,1,1)(1,1,1)_{12}$




Figura 13- Método SARIMA  $(1,1,3)(1,1,1)_{12}$




Figura 14- Método SARIMA  $(1,1,1)(0,1,1)_{12}$

De acordo com o critério de seleção escolhido (AIC), determina-se que o modelo SARIMA  $(1,1,1)(1,1,1)_{12}$  apresenta um melhor ajustamento, e por isso será o principal candidato para realizar a previsão.

## 5. Avaliação dos erros de previsão

### 5.1. Resultados da avaliação dos erros de previsão

Quanto aos métodos de Alisamento Exponencial, no *software Python*, aplicou-se o método de Alisamento Exponencial de Holt-Winters Multiplicativo, registrando-se um o valor de 186,54 para a Raiz do Erro Quadrático Médio (REQM), um valor de 142,28 para o Erro Absoluto Médio (EAM) e um valor de 3,59% para o Erro Percentual Absoluto Médio (EPAM). Aplicou-se ainda o método de Alisamento Exponencial com Tendência Aditiva Amortecida e Sazonalidade Multiplicativa, registrando-se um o valor de 180,26 para a Raiz do Erro Quadrático Médio (REQM), um valor de 135,24 para o Erro Absoluto Médio (EAM) e um valor de 3,39% para o Erro Percentual Absoluto Médio (EPAM).

Através das medidas de precisão da previsão, conclui-se que o melhor método a utilizar é o Alisamento Exponencial com Tendência Aditiva Amortecida e Sazonalidade Multiplicativa.

Quanto aos modelos SARIMA, no *software Python*, aplicou-se o modelo SARIMA (1,1,1)(1,1,1)<sub>12</sub>, registrando-se um valor de 200,86 para a Raiz do Erro Quadrático Médio (REQM), um valor de 156,71 para o Erro Absoluto Médio (EAM) e um valor de 3,96% para o Erro Percentual Absoluto Médio (EPAM). De seguida aplicou-se o modelo SARIMA (1,1,3)(1,1,1)<sub>12</sub> registrando-se um valor de 215,51 para a Raiz do Erro Quadrático Médio (REQM), um valor de 170,89 para o Erro Absoluto Médio (EAM) e um valor de 4,34% para o Erro Percentual Absoluto Médio (EPAM). Por fim, aplicou-se o modelo SARIMA (1,1,1)(0,1,1)<sub>12</sub> registrando-se um valor de 170,67 para a Raiz do Erro Quadrático Médio (REQM), um valor de 124,43 para o Erro Absoluto Médio (EAM) e um valor de 3,11 % para o Erro Percentual Absoluto Médio (EPAM).

Utilizando as medidas de precisão da previsão, conclui-se que o melhor modelo a utilizar é o SARIMA (1,1,1)(0,1,1)<sub>12</sub>.

#### Erros de previsão dos modelos:

	REQM	EAM	EPAM (%)
Holt-Winters Multiplicativo	186.54	142.28	3.59
Tendência Aditiva Amortecida e Sazonalidade Multiplicativa	180.26	135.24	3.39
SARIMA (1,1,1)(1,1,1) <sub>12</sub>	200.86	156.71	3.96
SARIMA (1,1,3)(1,1,1) <sub>12</sub>	215.51	170.89	4.34
SARIMA (1,1,1)(0,1,1) <sub>12</sub>	170.67	124.43	3.11

Tabela 3- Erros de previsão dos modelos selecionados

Conclui-se que, entre todos os modelos utilizados para fazer previsão, o modelo SARIMA (1,1,1)(0,1,1)<sub>12</sub> é aquele que apresenta menores erros.



## 6. Previsão para o futuro com o melhor modelo

Realizou-se uma previsão para os 12 meses futuros utilizando o modelo SARIMA  $(1,1,1)(0,1,1)_{12}$ . Visto que a presente série consiste num conjunto de dados mensais, de janeiro de 2010 a dezembro de 2021, sobre o consumo, em GWh, de eletricidade em Portugal, quer prever-se o mesmo consumo para o ano de 2022.

Na figura 15 pode-se visualizar a previsão para o período de teste, ou seja, a previsão das 29 últimas observações. Assim, conclui-se que os valores previstos para este período estão inseridos no intervalo de confiança a 95%, o que significa que estes são adequados para a previsão. A figura 16 apresenta a previsão para os 12 meses futuros.




Figura 15- Previsão no período de teste com o modelo SARIMA  $(1,1,1)(0,1,1)_{12}$  (usando o comando scalecast)




Figura 16- Previsão futura com o modelo SARIMA  $(1,1,1)(0,1,1)_{12}$  (usando o comando predict)

Observando e comparando as figuras 17 e 18, é possível verificar que no período de pandemia, a partir de março de 2020, a série original apresenta maiores oscilações do que a série modificada (figura 18).

Realizou-se uma previsão que não contempla os dados dos meses que coincidiram com o confinamento, isto é, substituíram-se os dados de abril de 2020 até dezembro de 2022 pela previsão do modelo SARIMA  $(1,1,1)(0,1,1)_{12}$ .

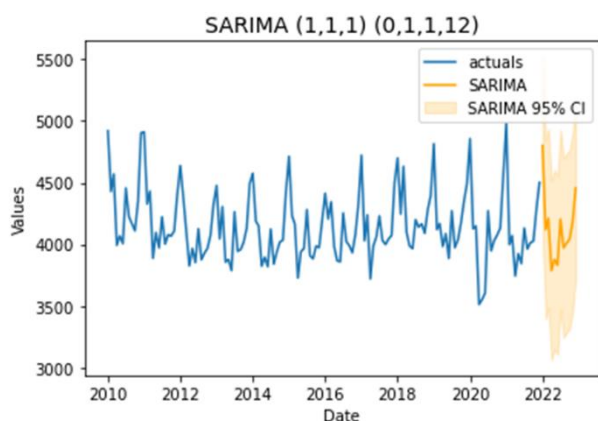


Figura 17- Previsão futura com o modelo SARIMA  $(1,1,1)(0,1,1)_{12}$  (usando o comando scalecast)




Figura 18-Previsão futura com o modelo SARIMA  $(1,1,1)(0,1,1)_{12}$  (usando o comando scalecast), removendo o efeito da covid-19

A figura 19 compara os valores da série original com os valores previstos sem a influência da covid-19, verificando-se que estes últimos têm uma amplitude menor, e estão mais afastados dos valores da série original nos meses de abril a junho de 2020 e no mês de janeiro de 2021. Os baixos valores verificados em abril de 2020 devem-se ao início do confinamento em Portugal que começou em março de 2020 e à consequente diminuição do uso de transportes tanto a nível pessoal como a nível logístico, bem como ao encerramento de algumas empresas e fábricas. Por contrapartida, o pico observado em janeiro de 2021 deve-se não só as características desta altura do ano, nomeadamente, os dias mais curtos e temperaturas mais baixas, como também a um novo confinamento. Este não obrigou ao fecho de empresas, no entanto, muitas destas optaram pelo regime de teletrabalho. Além disto, os estudantes foram também forçados a adotar este regime.




Figura 19- Previsão sem influência da covid-19 e os dados reais do Consumo Mensal de Eletricidade em Portugal (em GWh)

Como é observável na figura 20, a previsão desta série para 2022, em comparação com o ano anterior, apresenta comportamentos similares, isto é, as características sazonais da série continuam a evidenciar tanto os picos, como as diminuições de consumo na mesma altura do ano.

Em janeiro de 2022 prevê-se um consumo de 4801 GWh, uma redução de 3,69% face ao período homólogo, já em julho o consumo previsto é de 4203 GWh, um crescimento de 1,74% relativamente a 2021. O consumo médio mensal de eletricidade em Portugal previsto para 2022 é de aproximadamente 4124 GWh. Estas comparações são baseadas nos dados originais de 2021 e nos valores da previsão para 2022 com os dados originais.

Observa-se, pela figura 20, que de um modo geral, a previsão futura excluindo os efeitos da covid-19 apresenta valores mais elevados comparativamente à previsão futura com os dados originais, tal como seria de esperar.




Figura 20- Previsão futura sem influência da covid-19 e com dados reais do Consumo Mensal de Eletricidade em Portugal (em Gwh)

## 7. Previsão para o futuro com uma combinação dos três melhores modelos

### 7.1. Resultados da previsão com combinação dos três melhores modelos

Utilizaram-se os três melhores modelos, ou seja, o modelo SARIMA (1,1,1)(0,1,1)<sub>12</sub>, o método de Tendência Aditiva Amortecida e Sazonalidade Multiplicativa, e o método de Holt-Winters Multiplicativo.




Figura 21- Previsão futura com combinação dos modelos usando uma média simples




Figura 22- Previsão futura com combinação dos modelos usando uma média ponderada

Para avaliar estas combinações, podem obter-se os erros de previsão. Deste modo, foi realizada a previsão para o período de teste usando ambas as combinações e posteriormente estas foram avaliadas, como é visível na tabela 4.

	REQM	EAM	EPAM (%)
Combinação dos modelos através de uma média simples	178.43	133.48	3.35
Combinação dos modelos através de uma média ponderada	260.88	211.82	5.41
SARIMA (1,1,1)(0,1,1) <sub>12</sub>	170.67	124.43	3.11

Tabela 4- Erros de previsão das combinações de modelos e do melhor modelo

Comparando os modelos, é notório que ambas as combinações, tanto através da média simples como através da média ponderada, apresentam piores resultados do que o modelo escolhido (SARIMA (1,1,1)(0,1,1)<sub>12</sub>) para realizar a previsão. Assim, o modelo de previsão para o futuro mantém-se individual.

## 8. Conclusão

O objetivo deste estudo consiste na previsão do consumo mensal, em GWh, de eletricidade em Portugal, nos próximos 12 meses. A previsão é calculada com recurso ao *Software Python*, onde é selecionado o modelo de previsão com melhores resultados. Esta seleção foi feita com base num critério de comparação entre os erros de previsão dos vários modelos selecionados.

O melhor modelo selecionado é extraído dos modelos SARIMA, ou seja, entende-se que para a série em estudo, o modelo mais complexo apresenta melhores resultados.

É de salientar que os resultados obtidos com a combinação dos três melhores modelos (dois de alisamento exponencial e um ARIMA) não superaram os alcançados com o melhor modelo anteriormente selecionado. Este acontecimento deve-se ao facto de as previsões dos três melhores modelos apresentarem características muito similares, isto é, existe pouca diversidade nas previsões. Deste modo, a diferença apresentada entre os modelos não é suficiente para atingir o objetivo da combinação dos modelos.

Utiliza-se o modelo SARIMA (1,1,1) (0,1,1)<sub>12</sub> de modo a projetar uma previsão nos 12 meses seguintes, onde é possível visualizar as características sazonais da série. A variação da previsão do consumo mensal de eletricidade é expectável devido à sazonalidade da série e ao comportamento semelhante que se verificou ao longo dos anos anteriores.

Com a análise realizada, conclui-se que os dados recolhidos não são significativamente influenciados pelo período pandémico.

## 9. Referências

Redes Energéticas Nacionais. REN Data Hub. Consultado em 23 mar. 2022. Disponível em <https://datahub.ren.pt/>

Hyndman, R. e Athanasopoulos, G. (2014): Forecasting: Principles and Practice, OTexts.com


Makridakis, S., Wheelwright, S. e Hyndman, R. (1998): Forecasting: Methods and Applications, 3ª edição, John Wiley & Sons, New York

Brockwell, P. and Davis, R. (2016): Introduction to Time Series and Forecasting, 3rd edition, Springer


Direção-Geral de Energia e Geologia (2021). Energia em Números, edição 2021. Consultado em 3 jun. 2022. Disponível em <https://www.dgeg.gov.pt/pt/destaques/energia-em-numeros-edicao-2021/>

Lusa (2021, Janeiro 5). Consumo de eletricidade em 2020 foi o menor dos últimos 15 anos. Público.


## Anexos



Anexo 1- Correlograma dos resíduos do modelo SARIMA (1,1,1)(1,1,1)12



Anexo 2- Correlograma dos resíduos do modelo SARIMA(1,1,3)(1,1,1)12



Anexo 3- Correlograma dos resíduos do modelo SARIMA (1,1,1)(0,1,1)12